

NAPOMENA: Projekat se radi u kombinaciji sa predmetom Sistemi za istraživanje i analizu podataka (SIAP).

1. Tim

- **Boris Letić** (E2 126/2025) - Sentiment Analysis Branch (BERT fine-tuning, GRU agregacija)
- **Bogdan Čipčić** (R2 28/2025) - Price Time Series Branch (Stacked LSTM, Fusion Module)

2. Definicija problema

Razvoj multimodalnog deep learning sistema za predikciju kratkoročnog kretanja Bitcoin cene (24h, 48h, 7 dana) integracijom Twitter sentiment analize i vremenskih serija istorijskih cena.

Formulacija:

- **Regresija:** Predikcija tačne cene (price_24h, price_48h, price_7d)
- **Klasifikacija:** Predikcija pravca - UP ($>+2\%$), DOWN ($<-2\%$), STABLE ($[-2\%, +2\%]$)

Motivacija: Crypto tržište je izuzetno volatilno i osetljivo na sentiment sa društvenih mreža. Twitter sentiment može imati lag 6-12h pre uticaja na cenu, što omogućava predikciju.

3. Skup podataka

Twitter sentiment (Boris):

- Izvor: Kaggle "Bitcoin Tweets" dataset
- Veličina: ~10,000 tweets (#Bitcoin, #BTC, \$BTC) za Jan-Maj 2024
- Features: Sentiment scores (pozitivan/neutran/negativan), tweet volume, engagement metrics
- Preprocessing: NLTK tokenizacija, lemmatizacija, balansiranje klasa

Bitcoin cene (Bogdan):

- Izvor: Yahoo Finance API (yfinance)
- Period: Jan-Maj 2024 (hourly data, ~3,600 observacija)
- Features: OHLCV + tehnički indikatori (RSI, MACD, Bollinger Bands, SMA, EMA, ATR) + lag features

Podela podataka (temporal split):

- Training: 60% (Jan-Mart)
- Validation: 20% (April)
- Test: 20% (Maj)

4. Metodologija**Multimodalna arhitektura sa 3 branch-a:****Sentiment Branch (Boris):**

- BERT fine-tuning (bert-base-uncased) za sentiment klasifikaciju
- GRU (2 layers, 64 units)
- Bidirectional LSTM (2 layers, 128 units) kao alternativa GRU-u za tweet sequence encoding
- Output: 64-dim sentiment embedding

Price Branch (Bogdan):

- Stacked LSTM (128→64→32 units, Dropout 0.3)
- 1D CNN (Conv1D: 64→128→64 filters) za candlestick pattern recognition kao alternativa LSTM-u
- Input: 168h window OHLCV + tehnički indikatori (~28 features)
- Output: 64-dim price embedding

Fusion Module (Bogdan):

- Multi-Head Attention (4 heads) za fuziju embeddings
- Dense layers: 128→64→32 units
- Output: Regresija (1 neuron) ili Klasifikacija (3 neurona, Softmax)

Training setup:

- Loss: Huber (regresija), Categorical Cross-Entropy (klasifikacija)
- Optimizer: Adam (lr=0.001), ReduceLROnPlateau
- Regularizacija: Dropout 0.3-0.4, L2=0.01, Early Stopping, Gradient Clipping
- Batch size: 32, max 50 epochs

Baseline modeli:

1. LSTM-only (bez sentimenta)
2. VADER sentiment + Logistic Regression
3. Random Forest / XGBoost
4. ARIMA

5. Evaluacija**Regresione metrike:**

- RMSE (target <\$500 za 24h)
- MAE (target <\$400)
- MAPE (target <3%)
- R^2 (target >0.5)

Klasifikacione metrike:

- Directional Accuracy (target >55%, random=33%)
- F1-Score weighted (target >0.60)
- Confusion Matrix (UP/DOWN/STABLE analiza)

Kvalitativna analiza:

- Top-K errors analysis