

Predikcija Bitcoin cene korišćenjem multimodalnih dubokih neuronskih mreža

Boris Letić E2 126/2025, Bogdan Čiplic R2 28/2025

NAPOMENA: Projekat se radi u kombinaciji sa predmetima **Sistemi za istraživanje i analizu podataka (SIAP) i Neuronske mreže**. Specifikacija ispunjava zahteve oba predmeta.

1. Tim i podela rada

Timski članovi:

- Boris Letić (E2 126/2025) - Sentiment Analysis Branch i BERT fine-tuning
- Bogdan Čiplic (R2 28/2025) - Price Time Series Branch i Fusion Module

Specifična zaduženja (svaki član implementira barem jedan model):

- Boris: Fine-tuning BERT modela za crypto sentiment, implementacija GRU sentiment agregacije, baseline sentiment model (VADER lexicon + Logistic Regression)
- Bogdan: Implementacija Stacked LSTM za price prediction, Multi-Head Attention fusion mechanism, baseline price model (ARIMA + Linear Regression)
- Zajednički rad: Multimodalni fusion model, eksperimentalna evaluacija i ablation studies, pisanje IEEE rada

2. Definicija problema

Potrebno je razviti multimodalni deep learning sistem za predikciju kratkoročnog kretanja Bitcoin cene (24h, 48h, 7 dana unapred) integracijom Twitter sentiment analize i vremenskih serija istorijskih cena.

Problem se formuliše na dva načina:

1. Regresioni zadatak: Predikcija tačne cene u budućnosti (price_24h, price_48h, price_7d)
2. Klasifikacioni zadatak: Predikcija pravca kretanja - UP ($>+2\%$), DOWN ($<-2\%$), STABLE ($[-2\%, +2\%]$)

Sistem kombinuje BERT transformer za analizu sentimenta, LSTM rekurentne mreže za modelovanje price patterns, i Multi-Head Attention mechanism za fuziju podataka iz različitih modalnosti.

3. Motivacija problema

Crypto tržište karakteriše izuzetna volatilnost i visoka osetljivost na javni sentiment sa društvenih mreža. Twitter, kao glavna platforma crypto zajednice, generiše milione poruka dnevno koje nose informacije o kolektivnom raspoloženju investitora i mogu prethoditi kretanjima cena.

Tradicionalni pristupi analiziraju sentiment i cenu odvojeno, dok multimodalni deep learning može naučiti kompleksne nelinearne interakcije između različitih izvora informacija. Istraživanja pokazuju da sentiment sa društvenih mreža može imati lag od 6-12h pre nego što utiče na cenu, što otvara mogućnost za predikciju.

Praktična primena:

- Traderi mogu koristiti model za data-driven pristup odlučivanju i risk management
- Čak i mala poboljšanja u directional accuracy (>55% za ternary classification) mogu biti profitabilna uz odgovarajuće trading strategije
- Uncertainty estimation kroz Bayesian pristup omogućava procenu pouzdanosti predikcija

4. Pregled relevantne literature

4.1 Recurrent Neural Network Based Bitcoin Price Prediction by Twitter Sentiment Analysis

Tema rada: Predikcija Bitcoin cene koristeći LSTM sa Twitter sentiment-om i analizom njihove korelacije.

Podaci: Bitcoin cene 2016-2017 sa CoinMarketCap, ~1.6 miliona tweets sa Bitcoin hashtag-om. Features: OHLCV (Open, High, Low, Close, Volume) + sentiment score [-1, +1] dobijen VADER lexicon-om.

Metodologija: LSTM rekurentna mreža za modelovanje vremenskih serija cena, jednostavna konkatencija sentiment features sa price features, training na 80% podataka.

Evaluacija: 80/20 temporal split, RMSE (Root Mean Squared Error) kao mera greške. Postignut RMSE=\$412 na test setu, directional accuracy=67%.

Zaključak i naša nadogradnja: LSTM sa sentiment-om smanjuje RMSE za 18% u odnosu na LSTM samo sa cenama. Sentiment ima 6-12h lag pre uticaja na cenu. U našem projektu koristićemo *stacked multi-layer LSTM* umesto single layer, *BERT* umesto VADER-a za sofisticiraniju sentiment analizu, i *attention mechanism* umesto jednostavne konkatencije.

4.2 Price Movement Prediction of Cryptocurrencies Using Sentiment Analysis and Machine Learning

Tema rada: Klasifikacija pravca kretanja cena (Up/Down) za Bitcoin, Ethereum i Litecoin korišćenjem sentiment analize i ML modela.

Podaci: Dnevne cene 2017-2018 sa Coinbase, ~47,000 tweets sa CryptoCompare News API. Features: OHLCV, sentiment polarity/subjectivity, tweet volume, engagement metrics (likes, retweets).

Metodologija: Poređenje Random Forest, SVM, Logistic Regression i Neural Network (3-layer MLP). Korišćeni rolling window sentiment aggregates (mean, std, max sentiment za prethodnih 24h).

Evaluacija: 10-fold cross validation, F1-score, accuracy, confusion matrix. Neural Network postigao najbolji F1=0.74 za Bitcoin.

Zaključak i naša nadogradnja: Tweet volume jak prediktor volatilnosti, engagement metrics važniji od broja tweets-a. U našem projektu implementiraćemo *rolling window aggregates* za sentiment (6h, 12h, 24h windows), dodaćemo *tweet volume i engagement kao features*, i koristićemo *duboku neuronsku mrežu (5+ layers sa attention)* umesto shallow MLP.

4.3 Stochastic Neural Networks for Cryptocurrency Price Prediction

Tema rada: Predikcija kratkoročnih Bitcoin i Ethereum cena (1h, 24h ahead) koristeći stohastičke neuronske mreže sa uncertainty estimation.

Podaci: Hourly OHLCV podaci 2017-2019 sa Binance API, ~17,000 observations. Features: 14 tehničkih indikatora (RSI, MACD, Bollinger Bands) + raw price features, total 28 atributa.

Metodologija: Bayesian LSTM sa Monte Carlo dropout, kombinacija sa GRU i Attention mechanism. Walk-forward validation sa retraining svakih 7 dana.

Evaluacija: RMSE, MAE, MAPE, Directional Accuracy. Za Bitcoin 24h prediction: RMSE=\$287, Directional Accuracy=72%.

Zaključak i naša nadogradnja: Attention mechanism poboljšava performance za 11% nad basic LSTM. GRU+Attention najbolji za hourly prediction. U našem projektu koristićemo *attention-based arhitekturu* i *walk-forward validation* kao realističniji evaluation, dodaćemo *sentiment kao dodatni modality branch* što oni nisu radili, i implementiraćemo *tehničke indikatore kao features*.

5. Skup podataka

5.1 Twitter sentiment podaci

Izvori: Koristićemo Kaggle "*Bitcoin Tweets*" dataset ili Twitter API za prikupljanje ~50,000 tweets o Bitcoin-u (#Bitcoin, #BTC, \$BTC) za period Januar-Maj 2024.

Preprocessing pipeline:

- Uklanjanje URLs, mentions (@user), hashtags (#), lowercase konverzija
- Tokenizacija i lematizacija pomoću NLTK biblioteke
- Sentiment labeling u 3 klase: pozitivan (33%), neutralan (33%), negativan (33%)
- balansiran dataset

Ekstrahovanje dodatnih features:

- Rolling sentiment aggregates: mean, std, max sentiment za 6h, 12h, 24h windows
- Tweet volume po satu (broj tweets-a u svakom hour intervalu)
- Engagement metrics: likes, retweets, weighted engagement score
- Temporal features: hour_of_day, day_of_week za capture cikličnih obrazaca

5.2 Bitcoin cenovni podaci

Izvori: Yahoo Finance API (yfinance library) za hourly Bitcoin cene za period Januar-Maj 2024.

Raw price features: Open, High, Low, Close, Volume

Tehnički indikatori (izračunati koristeći 'ta' library):

- RSI (Relative Strength Index) - momentum oscillator
- MACD (Moving Average Convergence Divergence) - trend following
- Bollinger Bands (upper, middle, lower) - volatility indicator
- SMA, EMA (Simple/Exponential Moving Average) - trend smoothing
- ATR (Average True Range) - volatility measure

Engineered features:

- Lag features: Close price za t-6h, t-12h, t-24h, t-48h, t-7d
- Return features: hourly returns, daily returns, rolling volatilnost
- Price momentum features: rate of change (ROC) za različite periods

5.3 Ciljno obeležje (Target Variable)

Za regresiju:

- price_24h - Close price nakon 24 sata
- price_48h - Close price nakon 48 sati
- price_7d - Close price nakon 7 dana

Za klasifikaciju (ternary classification):

- direction_24h: UP (change > +2%), DOWN (change < -2%), STABLE (change ∈ [-2%, +2%])

5.4 Veličina datasea i podela

Ukupno: ~3,600 hourly observations (5 meseci × 30 dana × 24h)

Podela (striktni temporal split):

- Training set: 60% (Januar-Mart 2024) - ~2,160 samples
- Validation set: 20% (April 2024) - ~720 samples
- Test set: 20% (Maj 2024) - ~720 samples

Napomena: Striktno temporalna podela (ne shuffle) sprečava data leakage i simulira realistično trading scenario gde model mora predvideti budućnost.

6. Metodologija

Koristićemo multimodalnu deep learning arhitekturu sa tri specijalizovana branch-a koji procesiraju različite tipove podataka. Svaki branch ima svoju ulogu u ekstrakciji relevantnih features pre fuzije kroz attention mechanism.

6.1 Sentiment Analysis Branch (Boris)

BERT Fine-tuning: Pre-trained BERT model (bert-base-uncased) će biti fine-tuned na crypto sentiment dataset za klasifikaciju u 3 klase (pozitivan/neutalan/negativan). Koristi se Hugging Face Transformers biblioteka.

Arhitektura:

- BERT Tokenizer → BERT Base (12 layers, 768 hidden) → Classification Head
- Fine-tuning: Freeze prvih 8 layers, train zadnja 4 layers + classification head

- Learning rate: 2e-5, AdamW optimizer, 3 epochs

Sentiment Embedding Extraction: BERT [CLS] token embedding (768 dims) se agregira kroz GRU rekurentnu mrežu (2 layers, 64 units) koja procesira rolling sentiment features sa vremenskim window-om od 168h (7 dana). Izlaz je 64-dimenzijski sentiment embedding.

Input features za GRU: sentiment scores (rolling mean/std/max), tweet volume, engagement metrics, temporal features (hour, day).

6.2 Price Time Series Branch (Bogdan)

Stacked LSTM arhitektura:

- Layer 1: LSTM 128 units, return_sequences=True, Dropout(0.3)
- Layer 2: LSTM 64 units, return_sequences=True, Dropout(0.3)
- Layer 3: LSTM 32 units, return_sequences=False, Dropout(0.3)

Input sequence: 168h window (7 dana) OHLCV podataka + tehnički indikatori (RSI, MACD, Bollinger, SMA, EMA, ATR) + lag features + return features. Total ~28 features po timestep.

Output: 64-dimenzijski price embedding koji sadrži naučene reprezentacije price patterns.

6.3 Fusion Module (Zajednički rad)

Multi-Head Attention Mechanism: Embeddings iz oba branch-a se spajaju (128 dims) i procesiraju kroz Multi-Head Attention (4 heads) koji omogućava modelu da nauči važnost različitih modality u zavisnosti od tržišnih uslova.

Arhitektura:

- Concatenation layer: [sentiment_emb (64) + price_emb (64)] → 128 dims
- Multi-Head Attention: 4 heads, key_dim=32, Dropout(0.2)
- Dense layers: 128 → 64 → 32 units, ReLU activation, Dropout(0.4)
- Output layer: Linear activation (1 neuron za regresiju) ili Softmax (3 neurona za klasifikaciju)

6.4 Training Setup

Loss functions:

- Regresija: Huber Loss (robust na outliere, delta=1.0)
- Klasifikacija: Categorical Cross-Entropy sa class weights za balansiranje

Optimizer: Adam sa learning rate=0.001 i ReduceLROnPlateau scheduling (factor=0.5, patience=5)

Regularizacija:

- Dropout: 0.3-0.4 u svim layers
- L2 regularization: 0.01 kernel regularizer
- Early Stopping: patience=10 epochs, monitor validation loss
- Gradient Clipping: clip_norm=1.0 za stabilnost

Hiperparameters: Batch size=32, max 50 epochs (očekujemo early stopping ~30-35 epochs)

6.5 Baseline Modeli (Obavezno za poređenje)

Implementiraćemo sledeće baseline modele za poređenje sa našim multimodalnim deep learning pristupom:

Baseline 1 - LSTM-only model (bez sentimenta):

- Single-modality LSTM (2 layers, 128-64 units) treniran samo na price features
- Isti input window (168h) i evaluation protokol
- Cilj: Kvantifikovati doprinos sentiment modality-a

Baseline 2 - Klasični ML modeli:

- Linear Regression (za regresiju) sa feature engineering
- Random Forest Regressor/Classifier (n_estimators=100)
- XGBoost za benchmark naprednog tree-based modela

Baseline 3 - Sentiment-only baseline:

- VADER lexicon sentiment + Logistic Regression
- Demonstrira vrednost BERT-based sentimenta nad rule-based pristupom

Baseline 4 - Statistički model:

- ARIMA (Auto-Regressive Integrated Moving Average) za time series
- Grid search za best (p,d,q) parametere
- Demonstrira vrednost deep learning nad klasičnim statističkim pristupom

7. Postupak evaluacije i metrike

7.1 Eksperimentalni postupak

Walk-forward validation: Simulira realno trading scenario gde model predviđa buduće cene. Podela podataka je striktno temporalna (Training: Jan-Mart, Validation: April, Test: Maj) kako ne bi došlo do data leakage-a.

Evaluation protocol:

- Training na Jan-Mart (60%), hyperparameter tuning na Validation (20% - April)
- Final evaluation na Test set (20% - Maj) sa best hyperparameters
- Svi baseline modeli evaluiraju se na istom test set-u za fair comparison

7.2 Regresione metrike

RMSE (Root Mean Squared Error): Glavna mera greške, target <\$500 za 24h prediction

- Formula: $RMSE = \sqrt{(\sum (y_{pred} - y_{true})^2 / n)}$
- Interpretation: Prosečna apsolutna greška u dolarima

MAE (Mean Absolute Error): Robustnija na outliere, target <\$400

- Formula: $MAE = \sum |y_{pred} - y_{true}| / n$

MAPE (Mean Absolute Percentage Error): Relativna greška, target <3%

- Formula: $MAPE = (100/n) \times \sum |(y_{true} - y_{pred}) / y_{true}|$

R² (Coefficient of Determination): Target >0.5 (model objašnjava >50% varijanse)

- Formula: $R^2 = 1 - (SS_{res} / SS_{tot})$

7.3 Klasifikacione metrike

Directional Accuracy: Procenat tačno predviđenih smerova (UP/DOWN/STABLE)

- Target >55% (random guess = 33% za ternary classification)
- Posebno pratimo UP vs DOWN accuracy (kritično za trading)

F1-Score (weighted): Zbog mogućeg class imbalance, target >0.60

- Formula: $F1 = 2 \times (Precision \times Recall) / (Precision + Recall)$
- Weighted averaging preko klasa prema njihovoj zastupljenosti

Confusion Matrix: Detaljna analiza grešaka, posebno UP vs DOWN confusions

- Vizualizacija pomoću seaborn heatmap
- Analiza per-class precision/recall

7.4 Trading Simulation Metrike (Dodatna evaluacija)

Sharpe Ratio: Risk-adjusted returns, target >1.0

- Formula: $SR = (E[R_p - R_f]) / \sigma_p$
- Simulacija jednostavne strategije: Buy kada model predviđa UP, Hold za STABLE/DOWN

Maximum Drawdown: Target <20% (maksimalni gubitak od peak-a)

Win Rate: Profitable trades / total trades, benchmark sa Buy-and-Hold strategijom

7.5 Ablation Studies

Sprovešćemo ablation studies da kvantifikujemo doprinos različitih komponenti sistema:

- **Price-only vs Price+Sentiment:** Uticaj sentiment modality na performance
- **Sa/bez Attention mechanism:** Vrednost attention layer za fuziju
- **Window length comparison:** Test 24h, 72h, 168h windows
- **BERT vs VADER sentiment:** Vrednost transformer-based sentiment
- **Tehnički indikatori:** Impact dodatnih technical features

7.6 Kvalitativna analiza grešaka (OBAVEZNO)

Sprovešćemo dubinsku analizu primera gde je model napravio najveće greške da razumemo ponašanje modela:

- **Top-K Errors Analysis:** Analiza 20 najvećih prediction errors
- **Temporal Error Distribution:** Kada model najviše greši? (high volatility periodi, breaking news events)
- **Feature Importance Analysis:** Koje feature su najznačajnije u tačnim vs netačnim predikcijama?

- **Sentiment-Price Mismatch Cases:** Analiza situacija gde sentiment i cena nisu u skladu
- **Confusion Matrix Deep Dive:** Detaljno razumevanje UP/DOWN/STABLE konfuzija

Vizualizacija grešaka:

- Time series plot stvarnih vs predviđenih cena sa označenim velikim greškama
- Heatmap korelacije grešaka sa market features (volume spikes, volatilnost, sentiment shifts)
- Case studies: Odabir 5-10 reprezentativnih primera velikih grešaka sa detaljnom analizom konteksta

7.7 Interpretability (SHAP i Attention Weights)

SHAP Values za Feature Importance: Koristićemo SHAP (SHapley Additive exPlanations) library za analizu uticaja features na predikcije.

- SHAP summary plots za identifikaciju najvažnijih features
- Waterfall plots za individualne predikcije

Attention Weights Visualization: Analiza koje modality model koristi u različitim situacijama.

- Heatmap attention weights preko vremena
- Analiza kada model više pažnje posvećuje sentimentu vs ceni

8. Softver i tehnologije

Programming Environment: Python 3.9+ kao glavni jezik za razvoj.

Deep Learning Frameworks:

- PyTorch 2.0+ za implementaciju neuronskih mreža (LSTM, GRU, Attention layers)
- Transformers library (Hugging Face) za pre-trained BERT modele
- TorchMetrics za evaluacione metrike

Data Processing:

- Pandas i NumPy za data manipulation
- yfinance za Bitcoin price data
- 'ta' (Technical Analysis) library za tehničke indikatore
- NLTK za NLP preprocessing (tokenization, lemmatization)

Baseline Models:

- scikit-learn za ML algoritme (Random Forest, Linear Regression, Logistic Regression)
- XGBoost za gradient boosting baseline
- statsmodels za ARIMA model
- VADER (vaderSentiment) za rule-based sentiment baseline

Visualization:

- Matplotlib, Seaborn za statičke grafikone
- Plotly za interaktivne vizualizacije
- TensorBoard za monitoring treninga (loss curves, learning rate scheduling)

Interpretability:

- SHAP library za feature importance analysis
- Custom visualization code za attention weights

Compute Resources:

- Google Colab Pro (GPU: Tesla T4/V100) za BERT fine-tuning
- Paperspace Gradient (backup opcija)
- Lokalni development (CPU) za data preprocessing i baseline models

Version Control & Collaboration:

- Git + GitHub za version control
- Jupyter Notebooks za eksperimentaciju
- Python scripts za finalne modele